DESAFIO 3 - LEANDRO MARQUES E MIGUEL HONDA

Arquitetura e Protocolo Experimental

10 características de entrada. Uma classe correta entre três possibilidades

10	→	256	→	256	→	256	→	3
Entrada		Oculta 1		Oculta 1		Oculta 1		Saída 1

3 camadas ocultas: 0.5 * tanh

Logits → argmax

9600	Treino Ajusta os pesos	2400	Validação Escolhe a receita	3000	Teste Avalia a escolha

Padronização só no treino. 225 passos × lote 128 = 3 épocas.

Perda

Entropia cruzada

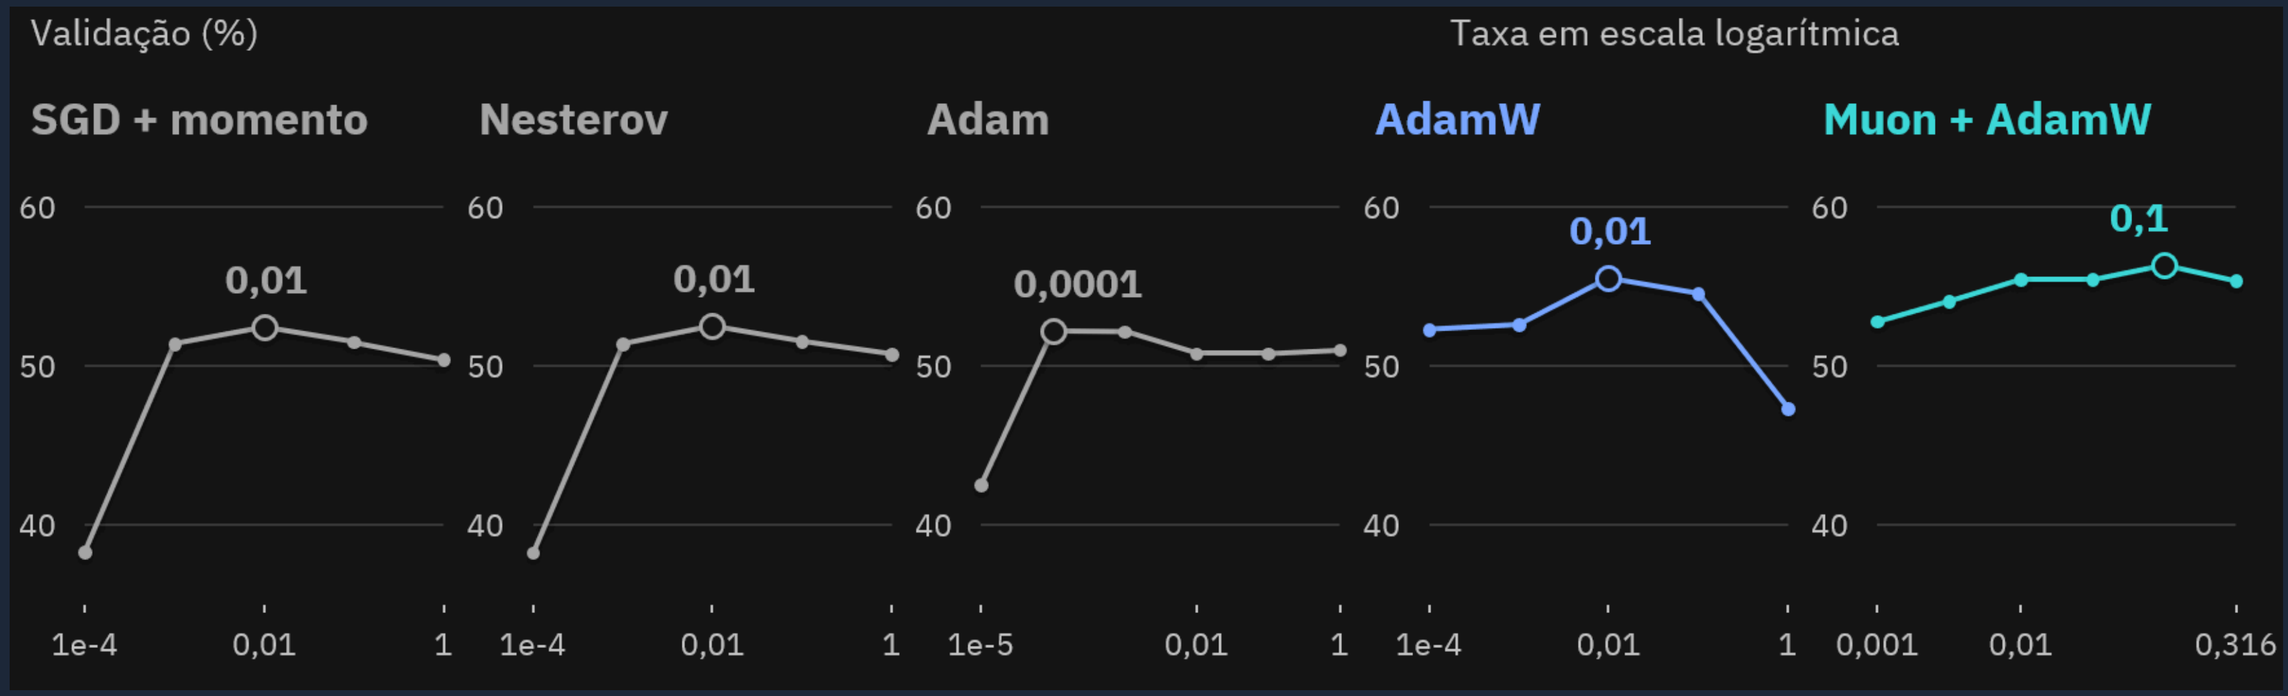
$L = -\ln(P_{correta})$

Recebe logits e calcula log-softmax. Exemplo:
$P = 0{,}9 \rightarrow L \approx 0{,}105$;
$P = 0{,}1 \rightarrow L \approx 2{,}303$

Uma classe correta por exemplo. Penaliza a baixa probabilidade da resposta correta; média no lote. Loss não é porcentagem de erros.

BUSCA DA TAXA DE APRENDIZADO

BASELINE 3 → BUSCA 27 → AGENDAS 8 → CONFIRMAÇÃO 9 → TESTE



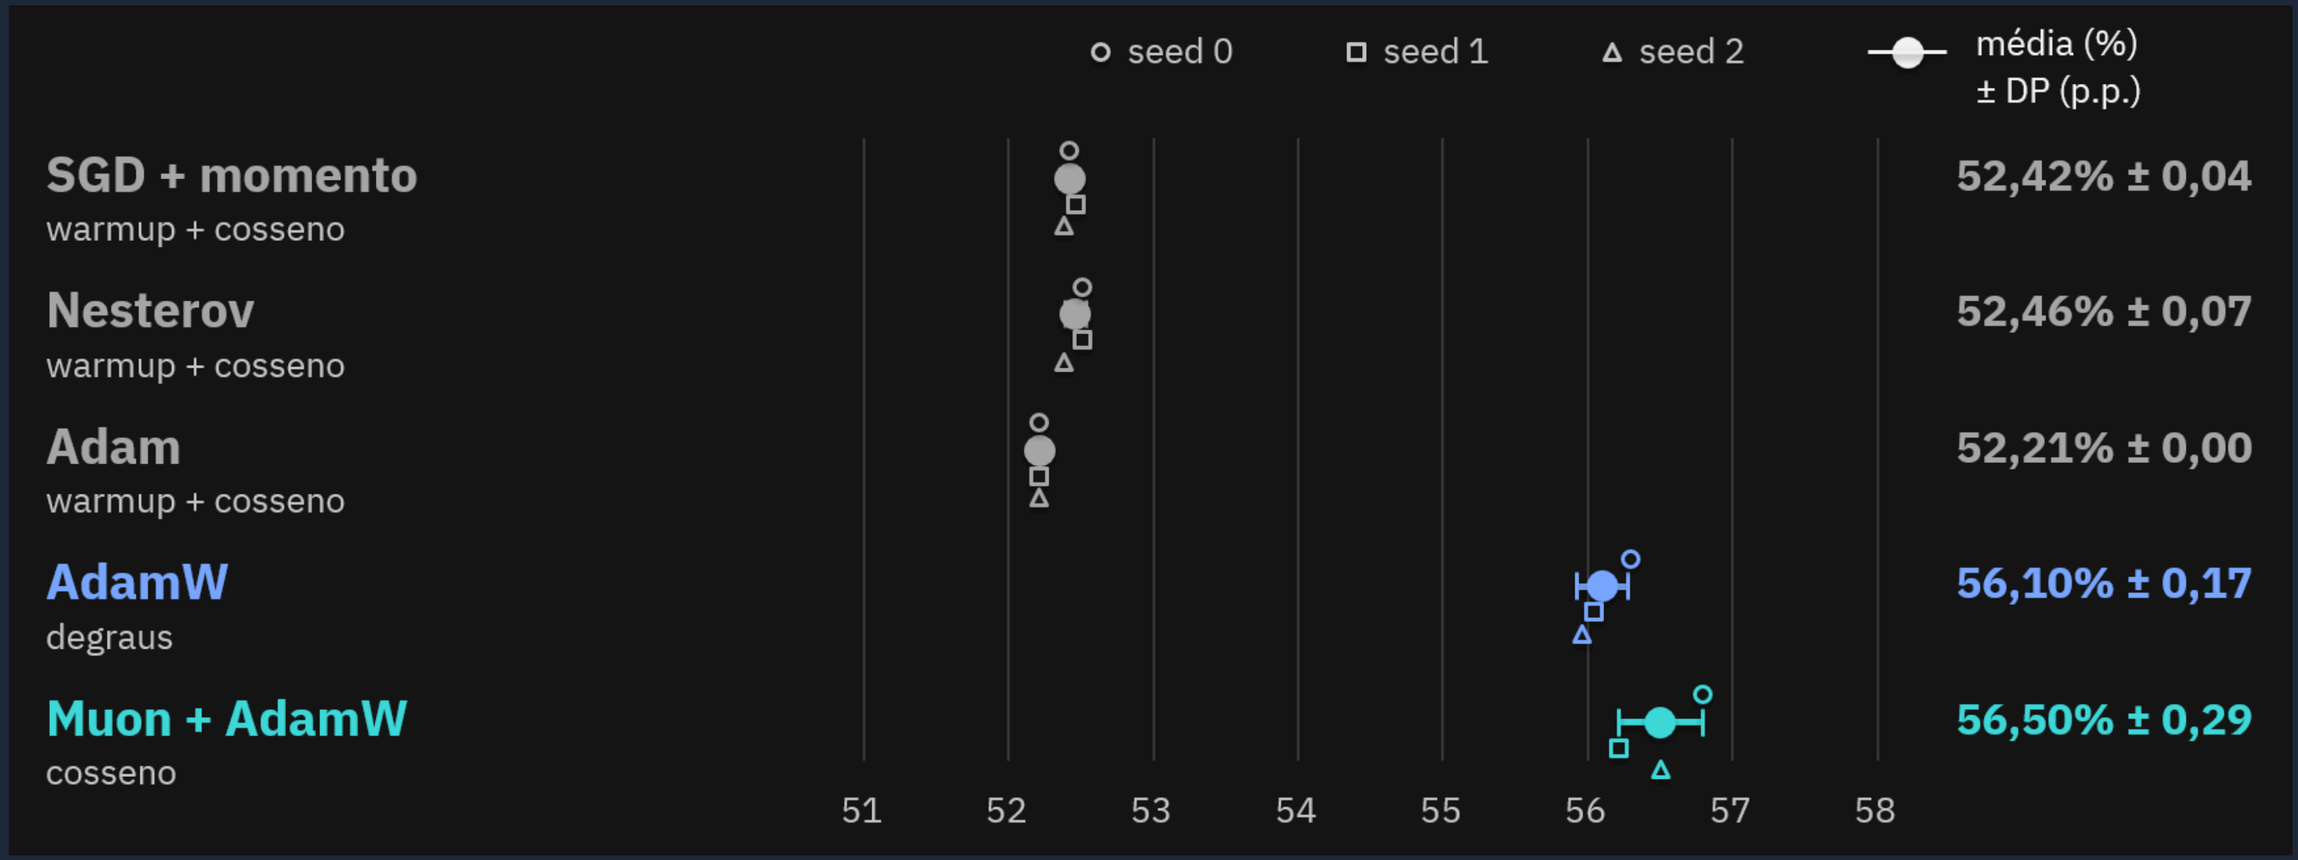
≥ 5 TAXAS POR OTIMIZADOR; FAIXA AMPLIADA NA BORDA. BUSCA COM SEED 0 E WARMUP + COSSENO.

AGENDAS: CONSTANTE, COSSENO, WARMUP + COSSENO E DEGRAUS. CONFIRMAÇÃO: SEMENTES 0, 1 E 2.

MUON: 5 ITERAÇÕES DE NEWTON-SCHULZ NAS MATRIZES OCULTAS. ADAMW AUXILIAR (0,01) NOS VIESES E NA SAÍDA, COM O MESMO FATOR DE AGENDA. IMPLEMENTAÇÕES PYTORCH.

Resultados por otimizador

60 treinos complementares: 5 otimizadores × 4 agendas × 3 sementes.



Acurácia de validação (%) · faixa ampliada de 51% a 58%

Coleta exploratória posterior ao teste original, sem novo teste.

Melhor agenda pela média das três sementes; taxas da busca original mantidas.

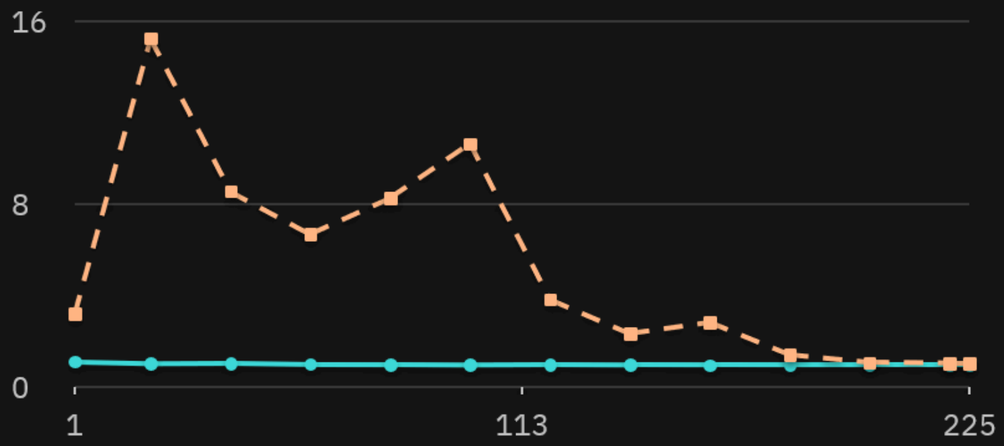
DINÂMICA DE TREINAMENTO E INSTABILIDADE

Muon + cosseno, taxa 0,1

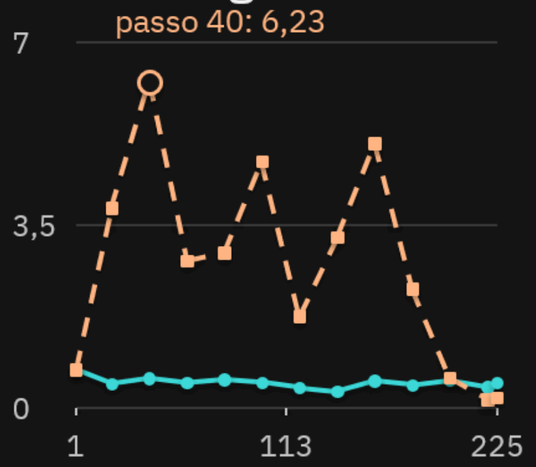
Adam + warmup/cosseno, taxa 1,0

Caso específico de instabilidade do Adam; valores finitos, sem divergência numérica.

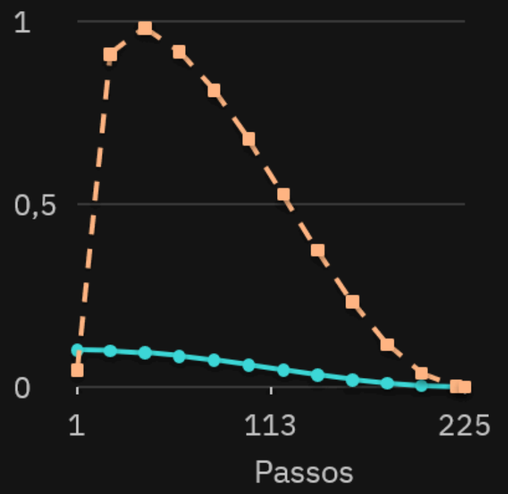
Perda de validação



Gradiente global



Taxa principal



Ampliação: só Muon



Loss: 1,0750 → 0,9312

||parâmetros||: 50,54 → 102,53

Gradiente máximo: 0,721.

Taxa e atualização finais: zero.

Passo 40 no caso Adam

Loss do lote: 18,75

||Δpesos|| / ||pesos|| = 0,413

RESULTADO FINAL E LIMITAÇÕES

GANHO PAREADO NA VALIDAÇÃO

+3.93 P.P.

± 0,61 P.P. ENTRE AS MESMAS SEMENTES

DIFERENÇA CANDIDATA − BASELINE POR SEMENTE; DEPOIS MÉDIA E DESVIO. CRITÉRIO DESCRITIVO, SEM TESTE DE SIGNIFICÂNCIA.

BASELINE

52.57% ± 0,85 P.P.

MUON + COSSENO

56.50% ± 0,29 P.P.

TESTE FINAL

54,87%

CHECKPOINT DA SEED 0

3.000 EXEMPLOS, UMA AVALIAÇÃO

RECEITA ESCOLHIDA

MUON 0,1 + ADAMW AUXILIAR 0,01; COSSENO; DECAY 0,01; 225 PASSOS; LOTE 128.

ADAMW FICOU PRÓXIMO E LEVOU MENOS TEMPO NA CPU OBSERVADA. TRÊS SEMENTES, TREINO CURTO, TEMPOS OBSERVACIONAIS E TESTE JÁ USADO NO TRABALHO ANTERIOR.

RECEITAS COMPLETAS: BASELINE SGD 0,05, CONSTANTE, DECAY ZERO. DIVISÃO POR LINHAS, SEM IDENTIFICAR PARTIDAS.